

Vector store i FAISS u semantičkoj pretrazi

Vector store je komponenta sistema koja čuva embedding vektore dokumenata. Svaki dio teksta, odnosno chunk, pretvara se u numerički vektor. Ti vektori se zatim koriste za brzo pronalaženje tekstova koji su semantički slični pitanju korisnika.

FAISS je biblioteka namijenjena efikasnoj pretrazi velikog broja vektora. U RAG sistemima FAISS se često koristi zato što može brzo pronaći najbliže vektore čak i kada postoji veliki broj dokumenata i chunkova.

Kada korisnik postavi pitanje, pitanje se takođe pretvara u embedding vektor. Zatim se taj vektor poredi sa vektorima svih chunkova koji su ranije indeksirani. Najsličniji chunkovi se vraćaju kao rezultat pretrage.

Za poređenje vektora mogu se koristiti različite metrike. Cosine similarity mjeri koliko su dva vektora slična po pravcu, dok Euclidean distance mjeri direktnu udaljenost između njih. U semantičkoj pretrazi teksta često se koristi cosine similarity jer dobro opisuje odnos značenja između tekstova.